

# Solution to the 4th Homework

Yimeng Zhu

November 30, 2019

## Contents

1	图像去畸变 (3 分, 约 1 小时)	2
2	双目视差的使用 (2 分, 约 1 小时)	3
3	矩阵运算微分 (2 分, 约 1.5 小时)	4
4	高斯牛顿法的曲线拟合实验 (3 分, 约 2 小时)	6
5	* 批量最大似然估计 (2 分, 约 2 小时)	7

## 1 图像去畸变 (3 分, 约 1 小时)

现实生活中的图像总存在畸变。原则上来说, 针孔透视相机应该将三维世界中的直线投影成直线, 但是当我们使用广角和鱼镜头时, 由于畸变的原因, 直线在图像里看起来是扭曲的。本次作业, 你将尝试如何对一张图像去畸变, 得到畸变前的图像。



图 1: 测试图像

图1 是本次习题的测试图像 (code/test.png), 来自 EuRoC 数据集 [1]。可以明显看到实际的柱子、箱子的直线边缘在图像中被扭曲成了曲线。这就是由相机畸变造成的。根据我们在课上的介绍, 畸变前后的坐标变换为:

$$\begin{cases} x_{distorted} = x(1 + k_1r^2 + k_2r^4) + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{distorted} = y(1 + k_1r^2 + k_2r^4) + p_1(r^2 + 2y^2) + 2p_2xy \end{cases} \quad (1)$$

其中  $x, y$  为去畸变后的坐标,  $x_{distorted}, y_{distorted}$  为去畸变前的坐标。现给定参数:

$$k_1 = -0.28340811, k_2 = 0.07395907, p_1 = 0.00019359, p_2 = 1.76187114e-05.$$

以及相机内参

$$f_x = 458.654, f_y = 457.296, c_x = 367.215, c_y = 248.375.$$

请根据 `undistort_image.cpp` 文件中内容, 完成对该图像的去畸变操作。

注: 本题不要使用 OpenCV 自带的去畸变函数, 你需要自己理解去畸变的过程。我给你准备的程序中已经有了基本的提示。作为验证, 去畸变后图像如图2所示。如你所见, 直线应该是直的。



图 2: 验证图像

**Solution:** see folder 1

## 2 双目视差的使用 (2 分, 约 1 小时)

双目相机的一大好处是可以通过左右目的视差来恢复深度。课程中我们介绍了由视差计算深度的过程。本题, 你需要根据视差计算深度, 进而生成点云数据。本题的数据来自 Kitti 数据集 [2]。

Kitti 中的相机部分使用了一个双目模型。双目采集到左图和右图, 然后我们可以通过左右视图恢复出深度。经典双目恢复深度的算法有 BM(Block Matching), SGBM(Semi-Global Block Matching)[[3], [4]] 等, 但本题不探讨立体视觉内容 (那是一个大问题)。我们假设双目计算的视差已经给定, 请你根据双目模型, 画出图像对应的点云, 并显示到 Pangolin 中。

本题给定的左右图见 `code/left.png` 和 `code/right.png`, 视差图亦给定, 见 `code/right.png`。双目的参数如下:

$$f_x = 718.856, f_y = 718.856, c_x = 607.1928, c_y = 185.2157$$

且双目左右间距 (即基线) 为:

$$d = 0.573m.$$

请根据以上参数, 计算相机数据对应的点云, 并显示到 Pangolin 中。程序请参考 `code/disparity.cpp` 文件。



图 3: 双目图像的左图、右图与视差

作为验证, 生成点云应如图4所示。



图 4: 双目生成点云结果

**Solution:** see folder 2

### 3 矩阵运算微分 (2 分, 约 1.5 小时)

在优化中经常会遇到矩阵微分的问题。例如, 当自变量为向量  $\mathbf{x}$ , 求标量函数  $\mu(\mathbf{x})$  对  $\mathbf{x}$  的导数时, 即为矩阵微分。通常线性代数教材不会深入探讨此事, 这往往是矩阵论的内容。我在 ppt/目录下为你准备了一份清华研究生课的矩阵论课件 (仅矩阵微分部分)。阅读此 ppt, 回答下列问题:

设变量为  $\mathbf{x} \in \mathbb{R}^N$ , 那么:

1. 矩阵  $\mathbf{A} \in \mathbb{R}^{N \times N}$ , 那么  $d(\mathbf{A}\mathbf{x})/d\mathbf{x}$  是什么?
2. 矩阵  $\mathbf{A} \in \mathbb{R}^{N \times N}$ , 那么  $d(\mathbf{x}^T \mathbf{A}\mathbf{x})/d\mathbf{x}$  是什么?
3. 证明:

$$\mathbf{x}^T \mathbf{A}\mathbf{x} = \text{tr}(\mathbf{A}\mathbf{x}\mathbf{x}^T). \quad (2)$$

**Solution:**

$$1. \text{ let } \mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \text{ then } \mathbf{A}\mathbf{x} \text{ can be interpreted as:}$$

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n \end{bmatrix}$$

According to Definition of  $d(\mathbf{A}\mathbf{x})/d\mathbf{x}$  in slides, the previous equation one can derive:

$$\begin{aligned} d(\mathbf{A}\mathbf{x})/d\mathbf{x} &= \begin{bmatrix} d(a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n)/dx_1 & \cdots & d(a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n)/dx_1 \\ d(a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n)/dx_2 & \cdots & d(a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n)/dx_2 \\ \vdots & \ddots & \vdots \\ d(a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n)/dx_n & \cdots & d(a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n)/dx_n \end{bmatrix} \\ &= \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{nn} \end{bmatrix} \\ &= \mathbf{A}^T \end{aligned}$$

Thus,  $d(\mathbf{A}\mathbf{x})/d\mathbf{x} = \mathbf{A}^T$

2. let  $\mathbf{A}$  and  $\mathbf{x}$  be defined as previous, one can multiply out:

$$\mathbf{x}^T \mathbf{A}\mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j$$

Further, one can derive:

$$d(\mathbf{x}^T \mathbf{A}\mathbf{x})/dx_k = d\left(\sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j\right)/dx_k = \sum_{i=1}^n a_{ik}x_i + \sum_{j=1}^n a_{kj}x_j = \sum_{i=1}^n (a_{ik} + a_{ki})x_i$$

Thus:

$$d(\mathbf{x}^T \mathbf{A} \mathbf{x})/dx = \begin{bmatrix} d(\sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j)/dx_1 \\ d(\sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j)/dx_2 \\ \vdots \\ d(\sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j)/dx_n \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n (a_{i1} + a_{1i}) x_i \\ \sum_{i=1}^n (a_{i2} + a_{2i}) x_i \\ \vdots \\ \sum_{i=1}^n (a_{in} + a_{ni}) x_i \end{bmatrix} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$$

3. From previous proof we know

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

Further we have

$$\begin{aligned} \mathbf{A} \mathbf{x} \mathbf{x}^T &= (\mathbf{A} \mathbf{x}) \mathbf{x}^T = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n \end{bmatrix} [x_1, x_2, \dots, x_n] \\ &= \begin{bmatrix} (a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n)x_1 & \cdots & \\ \vdots & \vdots & \\ \cdots & (a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n)x_n \end{bmatrix} \end{aligned}$$

Therefor,

$$\begin{aligned} tr(\mathbf{A} \mathbf{x} \mathbf{x}^T) &= (a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n)x_1 + \cdots + (a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n)x_n \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j \\ &= \mathbf{x}^T \mathbf{A} \mathbf{x} \end{aligned}$$

Thus,

$$tr(\mathbf{A} \mathbf{x} \mathbf{x}^T) = \mathbf{x}^T \mathbf{A} \mathbf{x}$$

## 4 高斯牛顿法的曲线拟合实验 (3 分, 约 2 小时)

我们在课上演示了用 Ceres 和 g2o 进行曲线拟合的实验, 可以看到优化框架给我们带来了诸多便利。本题中你需要自己实现一遍高斯牛顿的迭代过程, 求解曲线的参数。我们将原题复述如下。设有曲线满足以下方程:

$$y = \exp(ax^2 + bx + c) + w \quad (3)$$

其中  $a, b, c$  为曲线参数,  $w$  为噪声。现有  $N$  个数据点  $(x, y)$ , 希望通过此  $N$  个点来拟合  $a, b, c$ 。实验中取  $N = 100$ 。

那么, 定义误差为  $e_i = y_i - \exp(ax_i^2 + bx_i + c)$ , 于是  $(a, b, c)$  的最优解可通过解以下最小二乘获得:

$$\min_{a,b,c} \frac{1}{2} \sum_{i=1}^N \|y_i - \exp(ax_i^2 + bx_i + c)\|^2. \quad (4)$$

现在请你书写 Gauss-Newton 的程序以解决此问题。程序框架见 `code/gaussnewton.cpp`, 请填写程序内容以完成作业。作为验证, 按照此程序的设定, 估计得到的  $a, b, c$  应为:

$$a = 0.890912, b = 2.1719, c = 0.943629.$$

这和书中的结果是吻合的。

**Solution:** see folder 4

## 5 \* 批量最大似然估计 (2 分, 约 2 小时)

考虑离散时间系统:

$$x_k = x_{k-1} + v_k + w_k, \quad w \sim \mathcal{N}(0, Q)$$

$$y_k = x_k + n_k, \quad n_k \sim \mathcal{N}(0, R)$$

这可以表达一辆沿  $x$  轴前进或后退的汽车。第一个公式为运动方程,  $v_k$  为输入,  $w_k$  为噪声; 第二个公式为观测方程,  $y_k$  为路标点。取时间  $k = 1, \dots, 3$ , 现希望根据已有的  $v, y$  进行状态估计。设初始状态  $x_0$  已知。

请根据本题题设, 推导批量 (batch) 最大似然估计。首先, 令批量状态变量为  $\mathbf{x} = [x_0, x_1, x_2, x_3]^T$ , 令批量观测为  $\mathbf{z} = [v_1, v_2, v_3, y_1, y_2, y_3]^T$ , 那么:

1. 可以定义矩阵  $\mathbf{H}$ , 使得批量误差为  $\mathbf{e} = \mathbf{z} - \mathbf{H}\mathbf{x}$ 。请给出此处  $\mathbf{H}$  的具体形式。
2. 据上问, 最大似然估计可转换为最小二乘问题:

$$\mathbf{x}^* = \arg \min \frac{1}{2} (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{W}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x}), \quad (5)$$

其中  $\mathbf{W}$  为此问题的信息矩阵, 可以从最大似然的概率定义给出。请给出此问题下  $\mathbf{W}$  的具体取值。

3. 假设所有噪声相互无关, 该问题存在唯一的解吗? 若有, 唯一解是什么? 若没有, 说明理由。

**Solution:**

1.

$$\mathbf{H} = \begin{bmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

2.

$$\mathbf{W} = \begin{bmatrix} Q & 0 & 0 & 0 & 0 & 0 \\ 0 & Q & 0 & 0 & 0 & 0 \\ 0 & 0 & Q & 0 & 0 & 0 \\ 0 & 0 & 0 & R & 0 & 0 \\ 0 & 0 & 0 & 0 & R & 0 \\ 0 & 0 & 0 & 0 & 0 & R \end{bmatrix}$$

3. For  $\mathbf{x}^* = \arg \min \frac{1}{2} (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{W}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x})$ , it satisfies:

$$\left. \frac{\partial \frac{1}{2} (\mathbf{z} - \mathbf{H}\mathbf{x})^T \mathbf{W}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}^*} = -\mathbf{H}^T \mathbf{W}^{-1} (\mathbf{z} - \mathbf{H}\mathbf{x}^*) = \mathbf{0}$$

then it can be rewritten as:

$$(\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) \mathbf{x}^* = \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z}$$

If there is a unique solution for the above equation, the necessary and sufficient condition is

$$\text{rank}(\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) = \dim(\mathbf{x}^*) = 4$$

According to definition of  $\mathbf{W}$ ,  $W^{-1}$  can be simply written as:

$$\mathbf{W} = \begin{bmatrix} \frac{1}{Q} & 0 & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{Q} & 0 & 0 & 0 & 0 \\ 0 & 0 & \frac{1}{Q} & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{R} & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{R} & 0 \\ 0 & 0 & 0 & 0 & 0 & \frac{1}{R} \end{bmatrix}$$

Therefore,  $\mathbf{W}^{-1}$  is symmetric positive definite. It follows:

$$\text{rank}(\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}) = \text{rank}(\mathbf{H}^T \mathbf{H}) = \text{rank}(\mathbf{H}) = 4$$

Thus, the equation has a unique solution, and the the solution can be computed as:

$$\mathbf{x}^* = (\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z}$$



## References

- [1] M. Burri, J. Nikolic, P. Gohl, T. Schneider, J. Rehder, S. Omari, M. W. Achtelik, and R. Siegwart, “The euroc micro aerial vehicle datasets,” *The International Journal of Robotics Research*, 2016.
- [2] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? the kitti vision benchmark suite,” *2012 IEEE Conference On Computer Vision And Pattern Recognition (cvpr)*, pp. 3354–3361, 2012.
- [3] H. Hirschmuller, “Accurate and efficient stereo processing by semi-global matching and mutual information,” in *Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on*, vol. 2, pp. 807–814, IEEE, 2005.
- [4] D. Scharstein and R. Szeliski, “A taxonomy and evaluation of dense two-frame stereo correspondence algorithms,” *International journal of computer vision*, vol. 47, no. 1-3, pp. 7–42, 2002.